

---

**PREDVIĐANJE PONOVNE  
HOSPITALIZACIJE  
DIJABETIČKIH PACIJENATA U  
ROKU OD 30 DANA**

# CILJ

---

- Razviti model mašinskog učenja koji na osnovu podataka o bolničkom lečenju predviđa da li će dijabetički pacijent biti ponovo hospitalizovan u roku od 30 dana od otpusta, radi ranije identifikacije rizičnih pacijenata i boljeg planiranja resursa.
  - diabetic\_data.csv + IDS\_mapping.csv
  - Demografija, tok hospitalizacije, dijagnoze, laboratorija, terapija
  - 101766 poseta (uzoraka), 50 obeležja
  - Isključeni pacijenti sa ishodom smrt/hospis, 100.114 poseta preostalo

# INŽENJERSTVO KARAKTERISTIKA

---

Proces transformacije sirovih podataka u obeležja koja bolje opisuju problem i time poboljšavaju performanse modela mašinskog učenja.

- Manuelno

- Agregacije i sumarne statistike
- Enkodiranje kategoričkih promenljivih
- Ukrstanja obeležja
- Zasnovano na domenskom znanju
- Veća kontrola i interpretabilnost, ali sporije i podložno grešci

- Automatizovano

- Sistematska generacija kandidat-obeležja
- Automatska transformacija i skaliranje
- Automatska selekcija
- Manje zavisnosti od domenskog znanja
- Brže, ali teže objašnjivo i računski zahtevnije

# SAVREMENI TRENDОВI

---

- AutoML
  - Automatizacija celog toka (TPOT, H2O AutoML, AutoGluon i PyCaret)
- Deep Feature Synthesis
  - Automatsko generisanje obeležja agregacijom relacionih podataka (Featuretools)
- Automatska selekcija obelezja
  - Cognito, AutoLearn, HSIC Lasso
- Data-centric AI
  - Transformacija tabelarnih podataka, meta-učenje i generativni pristupi za kreiranje novih obeležja

# NEDOSTAJUĆE VREDNOSTI

---

| Obeležje          | Nedostajuće vrednosti |
|-------------------|-----------------------|
| Weight            | 98569                 |
| Medical_specialty | 49949                 |
| Payer_code        | 40256                 |
| max_glu_serum     | 96420                 |
| A1Cresult         | 84748                 |
| race              | 2273                  |

- Veza sa ciljnom promenljivom je slaba za sve kolone što isključuje MNAR
- diag\_3\_missing i max\_glu\_serum\_missing najjače zavise od drugih obeležja,
- weight isključena (96,85% nedostaje); ostale kolone popunjene kategorijama "Not\_Tested" / "Unknown" / "Missing"

# PODELA NA TRENING I TEST SKUP

---

- Skup sadrži 70.427 jedinstvenih pacijenata (23,40% ima više od jedne posete)
- Podela izvršena na nivou pacijenta

| Skup  | Broj uzoraka | Broj pacijenata |
|-------|--------------|-----------------|
| Train | 80041        | 56341           |
| Test  | 20049        | 14086           |

# PRIMENJENO INŽENJERSTVO KARAKTERISTIKA

---

- Klinička obeležja
  - total\_prior\_visits, acute\_prior\_visits
  - num\_med\_changes, num\_meds\_prescribed
  - labs\_per\_day, meds\_per\_day, procedures\_per\_day
  - Grupisanje ICD-9 dijagnoza (Diabetes, Circulatory, ...)
- Interacijska obelezja
  - age × number\_inpatient
  - time\_in\_hospital × num\_medications
  - num\_procedures × num\_lab\_procedures
  - total\_prior\_visits × num\_diagnoses
- Enkodiranje i skaliranje
  - 37 kategoričkih kolona - OrdinalEncoder (fit na treningu)
  - Numerička obeležja - StandardScaler (fit na treningu)
  - age\_numeric: sredina intervala starosti
  - Finalno: 60 kolona obeležja

# EFEKAT INŽENJERSTVA KARAKTERISTIKA I SMOTE-A

---

|                   | baseline (pre FE) | FE (bez SMOTE) | FE + SMOTE |
|-------------------|-------------------|----------------|------------|
| roc_auc           | 0.591586          | 0.664256       | 0.668781   |
| pr_auc            | 0.171786          | 0.215987       | 0.221513   |
| recall            | 0.324725          | 0.523773       | 0.015518   |
| precision         | 0.175501          | 0.184648       | 0.538097   |
| f1                | 0.227812          | 0.273038       | 0.030095   |
| specificity       | 0.804984          | 0.704543       | 0.998225   |
| balanced_accuracy | 0.564854          | 0.614158       | 0.506872   |
| brier_score       | 0.171356          | 0.202322       | 0.096019   |

# AUTOMATSKA OPTIMIZACIJA HIPERPARAMETARA

---

- Ray Tune
- ASHA scheduler
- 30 konfiguracija
- optimizacija PR-AUC
- 5-struka grupna unakrsna validacija (bez SMOTE)

## ❖ Prostor pretrage

- Dubina stabla i stopa učenja
- Subsample i colsample\_bytree
- min\_child\_weight
- L1/L2 regularizaciju (reg\_alpha, reg\_lambda)
- Broj estimatora

```
{'max_depth': 6,  
  'learning_rate': 0.016256670876862694,  
  'subsample': 0.8254442364744264,  
  'colsample_bytree': 0.5282057895135501,  
  'min_child_weight': 12,  
  'reg_alpha': 5.678201970293126,  
  'reg_lambda': 0.0010071984838809194,  
  'n_estimators': 543}
```


# FINALNI MODEL

---

|                   | baseline (dummy) | finalni model (test) |
|-------------------|------------------|----------------------|
| roc_auc           | 0.493972         | 0.675708             |
| pr_auc            | 0.112818         | 0.237975             |
| recall            | 0.102890         | 0.750000             |
| precision         | 0.103206         | 0.153908             |
| f1                | 0.103048         | 0.255405             |
| specificity       | 0.885055         | 0.469913             |
| balanced_accuracy | 0.493972         | 0.609956             |

# FINALNI MODEL

---



# ZAKLJUČAK

---

- Teorijska analiza pokazuje pomak ka automatizovanom inženjerstvu karakteristika, ali domensko znanje ostaje ključno za kliničke podatke
- Nedostajuće vrednosti su pretežno tipa MAR — zavise od posmatranih obeležja, ne direktno od ishoda readmisije.
- Ručno kreirana klinička i interakcijska obeležja donela su najveći doprinos poboljšanju performansi.
- SMOTE se pokazao kao loš izbor.
- Podešavanje praga prema kliničkom cilju ( $\text{recall} \geq 0,75$ ) omogućilo je identifikaciju većeg udela rizičnih pacijenata.
- Finalni XGBoost model optimizovan Ray Tune-om nadmašuje bazni model.